

Rapport Technique : Pipeline de Données Streaming

1. Description de la structure du Data Lake

Le Data Lake est organisé localement sous le dossier `data\_lake`, avec une structure hiérarchique comme suit :

```
/data_lake/  
├── transaction_log/  
│   ├── 2025-04-10/  
│   └── 2025-04-11/  
└── ...
```

Chaque `feed` Kafka correspond à un dossier principal, partitionné par date d'ingestion `YYYY-MM-DD`. Les fichiers sont au format Parquet. Le mode de stockage est `append` pour les streams.

2. Description de la structure du Data Warehouse

La base MySQL `data\_warehouse` contient :

- `users(user\_id, user\_name)`
- `transactions(...)` (liée à users par user_id)
- `shipping\_addresses(...)`
- `device\_info(...)`
- `permissions(...)`

Les relations sont gérées par clés étrangères.

3. Mécanisme de sécurité et droits d'accès

Table `permissions` :

- user_id
- lake_path
- permission_level (read, write, admin)

API FastAPI + dashboard Streamlit permettent de gérer dynamiquement les accès.

4. Orchestration

Orchestration assurée avec Apache Beam + `schedule`. Exécution toutes les 10 minutes :

- lecture Kafka
- écriture dans le Data Lake (parquet partitionné)

5. Monitoring (mise en place)

- Logs visibles (stdout)
- Dashboard Streamlit pour explorer les transactions
- Intégration future possible avec Grafana

6. Application de supervision automatique

Script Python pour vérifier les services clés (API, Beam, Consumers) et les redémarrer s'ils tombent :

Voir navigateur